

Seminario de investigación en Gestión y Valoración Urbana y Arquitectónica

MBArch 2025/2026

Carlos Marmolejo-Duarte

carlos.marmolejo@upc.edu

José Rojas-Quiroz

jose.carlos.rojas@upc.edu



Sesión 02

1. Los modelos de regresión lineal con estimación MCO (*aka* OLS)
2. Los modelos OLS y los errores
3. Los modelos OLS múltiples
4. Supuestos bajo los que se rigen los OLS
5. Los modelos OLS y la *logaritmización*
6. Los valores atípicos (*aka* outliers)
7. El método *Intro* vs. *Pasos sucesivos*
8. Autocorrelación espacial

Los modelos de regresión lineal con estimación MCO (*aka* OLS)

En su concepción más básica, corresponden a un método usado para **estimar** valores.


Nº habitaciones	Precio/m2 (€)
1	1,000
2	1,700
2	1,900
3	1,750
5	1,900
6	2,100

Necesita:

Una variable **de interés**, a estimar.
aka dependiente.

Una o más variables explicativas.
aka independientes.

Los modelos de regresión lineal con estimación MCO (aka OLS)



Necesita:


Una variable **de interés**, a estimar (Y).
Una o más variables independientes (X).

Su objetivo es encontrar una línea que pase lo más cerca posible de todos los puntos a la vez.

Con esa línea, podremos estimar valores que no tenemos a la mano.

¿Qué pasa si queremos saber el precio de un **piso con 4 habitaciones**?

Los modelos de regresión lineal con estimación MCO (aka OLS)



$$Y = \beta_0 + \beta_1 X_1$$


La **constante**, el
intercepto de la línea
con el eje Y.

La inclinación de la
línea

$$Y = 1258 + 147 \times 4$$

$$Y = 1846$$

Los modelos de regresión lineal con estimación MCO (aka OLS)



$$Y = \beta_0 + \beta_1 X_1$$


La **constante**, el
intercepto de la línea
con el eje Y.

La inclinación de la
línea

$$Y = 1258 + 147 \times 4$$

$$Y = 1846$$


Los modelos de regresión lineal con estimación MCO (aka OLS)



Si bien su función inicial puede ser la de estimar el valor de Y , también puede servir para cuantificar cómo X_1 le afecta.

$$Y = 1258 + 147 \times X_1$$


Los modelos de regresión lineal con estimación MCO (aka OLS)



$$Y = 1258 + 147 \times X_1$$

La inclinación de la recta, 147°, indica que por cada unidad que aumente el valor de X_1 , que es el número de habitaciones, el precio/m² aumenta 147 €.

Los modelos de regresión lineal con estimación MCO (aka OLS)




$$Y = 1258 + 147 \times X_1$$

Por su lado, el intercepto, 1258, es el precio/m² cuando $X_1=0$.
Es decir, cuando el número de habitaciones es **cero**.

En este caso, si una vivienda no tuviera habitaciones el precio de venta estimado sería 1258 €/m².

¿Por qué se dice que tiene una
estimación de Mínimos Cuadrados
Ordinarios?

Los modelos OLS y los errores



Siempre hay una diferencia entre los valores reales y los valores que estima un modelo. A eso se le conoce como **error** o **residuo**.

$$\varepsilon = Y - \check{Y}$$


Valor real de Y Valor de Y predicho por el modelo

$$1000 - 1300$$
$$-300$$

¿Cómo graficarían el cuadrado del error?


Los modelos OLS y los errores

Los modelos OLS buscan reducir el cuadrado del error de cada una de nuestras observaciones a la mínima medida posible.



Los modelos OLS y los errores

Los modelos OLS buscan reducir el cuadrado del error de cada una de nuestras observaciones a la mínima medida posible.




Los modelos OLS y los errores

El término “ordinarios” simplemente se usa para distinguirlo de otras variantes del método de mínimos cuadrados.

¡Existen muchos más modelos de regresión lineal!


Y existen muchos más modelos de regresión que no son lineales... pero los OLS son los más aceptados en el mundo inmobiliario.



¿Y cómo graficamos un modelo de
regresión con más de una variable
explicativa?

Los modelos de regresión lineal múltiple

¿Qué pasa si quisiéramos estudiar el impacto de dos variables sobre el precio/m²? El gráfico se vería así:



Graficar una regresión lineal múltiple es una tarea más compleja, pero la notación matemática sigue siendo la misma.

Los modelos de regresión lineal múltiple

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$$

Nº habitaciones Calidad del baño (1-5) Calidad de las ventanas (1-5)


$$Y = 1258 + 147 \times X_1 + 250 \times X_2 + 116 \times X_3 + \varepsilon$$

Si añadir una habitación, mejorar la calidad de un baño o mejorar la calidad de ventanas valiera lo mismo, ¿a qué destinarían el dinero de una rehabilitación para vender el piso a mayor valor?


Supuestos bajo los que se rigen los OLS

Modelos OLS

Homosedasticidad



Normalidad de los errores



No multicolinealidad

VIF

Supuestos bajo los que se rigen los OLS

1. Homosedasticidad

Ya sabemos que el error (residuo) es la diferencia entre el valor observado de la variable dependiente y el valor predicho por el modelo.



La homocedasticidad implica que no importa si tienes un valor bajo o alto en la predicción de la variable independiente, la dispersión de los errores debería ser siempre la misma en todo el dataset.

Dicho de otra manera significa que tu “margen de error” debería ser similar tanto si valoras un piso de €100,000 como uno de €500,000. Si tu error crece mucho con pisos más caros, tienes heterocedasticidad.

Supuestos bajo los que se rigen los OLS

1. Homoscedasticidad

Puedes graficar los residuos del modelo frente a las predicciones del modelo (en su versión estandarizada). Si los puntos no forman un patrón claro es porque estamos ante una situación de homoscedasticidad.




Supuestos bajo los que se rigen los OLS

2. Normalidad de los errores

La normalidad de los errores es necesaria porque las fórmulas matemáticas que usa OLS para calcular intervalos de confianza y pruebas de hipótesis asumen que los errores siguen una distribución normal.

Piénsenlo así: cuando el modelo dice “el precio de la vivienda aumenta €50,000 por cada metro cuadrado adicional, con un 95% de confianza”, ese *95% de confianza* se calcula asumiendo que los errores están distribuidos normalmente. Si no lo están, esos intervalos y conclusiones estadísticas pierden validez.

Asumimos normalidad porque nos permite hacer inferencias confiables sobre los coeficientes (y su p-valor). Si los residuos no son normales, podría indicar que hay patrones no explicados, valores atípicos, o que falta incluir alguna variable relevante.



Supuestos bajo los que se rigen los OLS

3. No multicolinealidad

Hace referencia a la autocorrelación entre variables explicativas. Si es muy fuerte puede sesgar los coeficientes de algunas de ellas.

Cuando hay multicolinealidad alta, el modelo “no sabe” a qué variable atribuirle el efecto, inflando artificialmente los errores estándar y haciendo que variables importantes parezcan no significativas.

¿Cómo se mide?

A través del Factor de Inflación de la Varianza (VIF), que es un indicador que “captura” la correlación entre todas las variables a la vez.

Modelo		Coeficientes no estandarizados		Coeficientes estandarizados	t	Sig.	Estadísticas de colinealidad	
		B	Desv. Error	Beta			Tolerancia	VIF
1	(Constante)	-268854,942	30935,751		-8,691	<,001		
	EPC_A_emision	128022,592	42391,142	,047	3,020	,003	,998	1,002
	pr_directivo	50527,526	1525,441	,755	33,123	<,001	,465	2,148
	pr_no_calif	16913,537	1810,263	,215	9,343	<,001	,458	2,181
	interac_planta	10087,244	1465,091	,112	6,885	<,001	,916	1,092


a. Variable dependiente: precio_eur

< 3


Supuestos bajo los que se rigen los OLS

Modelos OLS

Homosedasticidad



Normalidad de los errores



No multicolinealidad


VIF

1. El primer supuesto es el más rígido. Sí o sí debemos cumplir con él.
2. Con el segundo supuesto podemos ser flexibles, pues rara vez vamos a encontrar una normalidad perfecta en nuestros errores.
3. Con el tercer supuesto podemos ser flexibles siempre que tengamos una base teórica para la inclusión de dos variables con multicolinealidad.


Supuestos bajo los que se rigen los OLS

Sobre la flexibilidad para el tercer supuesto, veamos un ejemplo.

Relación entre precio y superficie



Relación entre precio y superficie al cuadrado



Supuestos bajo los que se rigen los OLS

Una primera aproximación:

1. Armen un modelo con la superficie, la superficie al cuadrado y cinco variables más de su preferencia. La variable a estimar será *precio_euros*.
2. Revisen sus coeficientes, significancia y el VIF.
3. Obtengan también un gráfico P-P para ver la distribución de sus residuos.
4. Finalmente, guarden sus residuos en una columna llamada *residuos_primer_ols*.

Prompt sugerido:

Tengo un GeoDataFrame llamado `gdf` con ofertas de viviendas en Barcelona. Quiero que me ayudes a hacer lo siguiente en Python, usando `statsmodels`, `pandas` y `numpy`:

1. Estima un modelo OLS donde la variable dependiente es `precio_euros` y las variables independientes son `superficie`, `superficie al cuadrado` (créala como `superficie_2`), y estas cinco adicionales: `[ustedes completan aquí]`.
2. Muestra el summary del modelo. Además, genera una tabla con el VIF de cada variable, usando `variance_inflation_factor` de `statsmodels.stats.outliers_influence`. La tabla debe tener dos columnas: `Variable` y `VIF`, ordenada de mayor a menor VIF, con dos decimales.
3. Genera un gráfico P-P de los residuos. Eje X: "Probabilidades teóricas (normal)", eje Y: "Probabilidades observadas". Añade una línea diagonal de referencia en rojo discontinuo.
4. Guarda los residuos en una nueva columna de `gdf` llamada `residuos_primer_ols`.

Supuestos bajo los que se rigen los OLS



Si decides seguir adelante con la violación de un supuesto es importante que:

1. Lo reportes de manera clara en tu investigación, ya sea en la descripción de la metodología o de los resultados.
2. Consideres que esto puede sesgar los coeficientes de las demás variables que ingresan al modelo, por lo que es importante interpretar/entender a profundidad cómo se están comportando.

¿Por qué a veces se usa el precio y otras veces el logaritmo natural del precio en un modelo?



Los modelos OLS y la *logaritmización*

En la práctica, la distribución de los errores se asocia con la distribución de la variable dependiente; en nuestro caso, el precio.





Los modelos OLS y la *logaritmización*

Así cambia la distribución de los residuos de un modelo tras aplicar la logaritmización al precio, manteniendo las mismas variables explicativas.



Los modelos OLS y la *logaritmización*

De *yapa*, con esta nueva variable me es más sencillo interpretar la relación con algunas variables explicativas.



Los modelos OLS y la *logaritmización*

Sin embargo, su aplicación supone un **cambio** en la **interpretación** de los coeficientes del modelo de regresión:

		Coeficientes no estandarizados	
Modelo		B	Desv. Error
1	(Constante)	-264229,802	16543,143
	EPC_A_emision	71019,655	21116,984
	pr_directivo	18289,883	848,860
	pr_no_calif	5805,845	911,873
	interac_planta	3462,163	735,082
	superficie	4218,879	74,914
	numero_habitaciones	-22265,851	2892,441
	numero_bano	56091,673	4540,014
	a. Variable dependiente precio_eur		

		Coeficientes no estandarizados	
Modelo		B	Desv. Error
1	(Constante)	11,699	,039
	EPC_A_emision	,193	,049
	pr_directivo	,035	,002
	pr_no_calif	-,005	,002
	interac_planta	,019	,002
	superficie	,006	,000
	numero_habitaciones	-,015	,007
	numero_bano	,125	,011
	a. Variable dependiente Ln_total_pr		

Un aumento de una unidad en *pr_directivo* para un piso supone un aumento de su precio en 18.289 euros.

Los modelos OLS y la *logaritmización*

Sin embargo, su aplicación supone un cambio en la interpretación de los coeficientes del modelo de regresión:

Modelo		Coeficientes no estandarizados	
		B	Desv. Error
1	(Constante)	-264229,802	16543,143
	EPC_A_emision	71019,655	21116,984
	pr_directivo	18289,883	848,860
	pr_no_calif	5805,845	911,873
	interac_planta	3462,163	735,082
	superficie	4218,879	74,914
	numero_habitaciones	-22265,851	2892,441
	numero_bano	56091,673	4540,014
a. Variable dependiente precio_eur			

Un aumento de una unidad en *pr_directivo* para un piso supone un aumento de su precio en 18,289 euros.

Modelo		Coeficientes no estandarizados	
		B	Desv. Error
1	(Constante)	11,699	,039
	EPC_A_emision	,193	,049
	pr_directivo	,035	,002
	pr_no_calif	-,005	,002
	interac_planta	,019	,002
	superficie	,006	,000
	numero_habitaciones	-,015	,007
	numero_bano	,125	,011
a. Variable dependiente Ln_total_pr			

Un aumento de una unidad en *pr_directivo* para un piso supone un aumento de su precio en 3.5%.

Los modelos OLS y la *logaritmización*

Al mismo modelo que crearon antes van a cambiarle la variable a estimar por *log_precio_euros* (la tienen que calcular primero).

Guarden sus residuos en una columna llamada *residuos_segundo_ols*.

Comparen:

- El gráfico P-P de este segundo modelo con el del primero. ¿Cuál se acerca más a la distribución normal en sus residuos?
- La distribución de *residuos_primer_ols* y *residuos_segundo_ols* a través de histogramas.

Prompt sugerido:

Siguiendo con el mismo gdf y el mismo modelo OLS de antes:

- 1.Calcula el logaritmo natural de *precio_euros* y guárdalo en una nueva columna llamada *log_precio_euros*.
- 2.Estima el mismo modelo OLS pero ahora con *log_precio_euros* como variable dependiente (mantén exactamente las mismas variables independientes, incluyendo *superficie_2*).
- 3.Guarda los residuos de este segundo modelo en una nueva columna de gdf llamada *residuos_segundo_ols*.
- 4.Genera una figura con dos paneles en fila:
 - Panel izquierdo: gráfico P-P de *residuos_primer_ols*. Título: "Modelo 1 – precio en euros".
 - Panel derecho: gráfico P-P de *residuos_segundo_ols*. Título: "Modelo 2 – log precio".
 - Ambos con línea diagonal roja discontinua y mismos ejes.
- 5.Genera una segunda figura con dos histogramas en fila, uno para cada columna de residuos. El eje Y debe mostrar densidad (no conteo). Superpón en cada histograma una curva de densidad (KDE) en color oscuro. Ambos paneles deben compartir el eje Y para facilitar la comparación. Títulos iguales que en el punto 4.

Los outliers

Los outliers corresponden a valores atípicos.

¿Nos será útil incluir en nuestro modelo pisos de 5 millones de euros sabiendo que la gente *normal* no compra este tipo de viviendas? ¿Y si tenemos pisos con 10 baños?

Su identificación corresponde a una tarea tediosa y bien pensada, que implica revisar los datos tanto de nuestra variable a explicar (el precio) y de las variables explicativas. Hay que considerar, además, que su aparición puede corresponder a situaciones anómalas en el mercado o a errores en la recolección de datos.

Los outliers

Una manera sencilla de identificarlos es revisando la variable de nuestro interés y aplicando dos umbrales:

$$\begin{aligned} &\text{Media} + \textit{Factor multiplicativo} * \text{Desviación estándar} \\ &\text{Media} - \textit{Factor multiplicativo} * \text{Desviación estándar} \end{aligned}$$

Todos aquellos casos con valores que queden fuera de estos umbrales se pueden considerar atípicos.

Usualmente el *factor multiplicativo* se considera como un valor de entre **1.5** y **2.5**, el cual se debe ir testeando hasta encontrar una distribución de nuestra variable que se acerque más a una de tipo normal.

Los outliers

Mi recomendación es proceder a su eliminación del dataset sólo si tras haber hecho un primer modelo de regresión que teóricamente nos satisfaga sigamos sin cumplir con los supuestos.

Y...¿Para qué hacemos un modelo?

El método *Intro* vs. *Pasos sucesivos*

Un modelo OLS puede servir para dos finalidades, que no son excluyentes entre ellas:

1. Predecir o estimar y

Resumen del modelo					
Modelo	R	R cuadrado	R cuadrado ajustado	Error estándar de la estimación	
1	,650 ^a	,423	,422	248706,295	

a. Predictores: (Constante), interac_planta, EPC_A_emision, pr_directivo, pr_no_calif

Coeficientes ^a					
		Coeficientes no estandarizados		Coeficientes estandarizados	
Modelo		B	Desv. Error	Beta	t
1	(Constante)	-268854,942	30935,751		-8,691
	EPC_A_emision	128022,592	42391,142	,047	3,020
	pr_directivo	50527,526	1525,441	,755	33,123
	pr_no_calif	16913,537	1810,263	,215	9,343
	interac_planta	10087,244	1465,091	,112	6,885

a. Variable dependiente: precio_eur

- ## 2. Entender y

El método *Intro* vs. *Por pasos sucesivos*

El método *por pasos* genera la mejor combinación de variables para obtener un R^2 -ajustado lo más alto posible. Como consecuencia, casi siempre arroja variables con un coeficiente estadísticamente significativo.

No siempre es ideal. Realicemos el siguiente ejercicio:

1. Obtén variables binarias a partir de la columna *EPC_e_calculado*.
2. Con ello, crea un modelo con el método por pasos sucesivos con todas las variables del modelo (excluyendo *EPC_e_calculado*)
3. Revisa los resultados y responde a la pregunta: ¿El modelo resultante te permite entender el impacto de todas la categorías EPC en el precio de las viviendas?

El método *Intro* vs. *Por pasos sucesivos*

El R^2 no puede ser el único indicador a revisar para decidir el modelo que usaremos.

Coeficientes y residuos son importantísimos dependiendo del objetivo de su investigación.

El método *Intro* vs. *Por pasos sucesivos*

LONG-TERM EFFECTS OF THE INCA ROAD

Ana Paula Franco
Sebastian Galiani
Pablo Lavado

Working Paper 28979

<http://www.nber.org/papers/w28979>

NATIONAL BUREAU OF ECONOMIC RESEARCH

1050 Massachusetts Avenue
Cambridge, MA 02138
July 2021

Figure 1: Route of the Inca Road in Peru





Figure 2: Treatment and Control Groups in the proximity of the Inca Road



El método *Intro* vs. *Por pasos sucesivos*

Antes de pasar a los detalles de la investigación, dense cuenta que los modelos OLS pueden servir para fines distintos a la valoración inmobiliaria.

El método *Intro* vs. *Por pasos sucesivos*

El Imperio Inca fue la última de una larga serie de culturas altamente desarrolladas en la Sudamérica precolonial. El Camino Inca era su sistema de transporte de 30.000 kilómetros de longitud.

El objetivo de este estudio es identificar su impacto a largo plazo en el desarrollo actual de Perú.

Los resultados muestran que el efecto a largo plazo del Camino Inca incluye un aumento de los salarios y del nivel educativo, una reducción de la malnutrición infantil y un aumento de los resultados de los niños en las pruebas de matemáticas.

El método *Intro* vs. *Por pasos sucesivos*

Table 2: Inca Road and development outcomes

	Dependent variable:							
	Log hourly wage, 2007-2017		Malnutrition, 2005 (% of 6-9 year old children)		Schooling, 2007-2017 (No. of years)		Math Test Score, 2015 (Std. Dev.)	
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
Mean of dep. var. [Std. Dev.]	2.150 [1.147]	2.150 [1.147]	0.443 [0.210]	0.443 [0.210]	7.406 [5.164]	7.406 [5.164]	4.622 [0.999]	4.622 [0.999]
Inca Road	0.105*** (0.037)	0.097*** (0.035)	-0.034*** (0.012)	-0.035*** (0.011)	1.642*** (0.336)	1.550*** (0.361)	0.256*** (0.030)	0.242*** (0.034)
<i>Baseline controls:</i>								
Year fixed effects	yes	yes			yes	yes		
Region fixed effects	yes	yes	yes	yes	yes	yes	yes	yes
Demographic controls	yes	yes			yes	yes	yes	yes
<i>GIS controls:</i>								
Elevation		yes		yes		yes		yes
Slope		yes		yes		yes		yes
Density of rivers		yes		yes		yes		yes
No. observations	115,641	115,641	10,153	10,153	151,398	151,398	1,068,070	1,068,070
R ²	0.306	0.307	0.168	0.197	0.335	0.338	0.051	0.052

* p-valor<0.1
** p-valor<0.05
***p-valor<0.001

Ejercicio de interpretación

Resumen del modelo				
Modelo	R	R cuadrado	R cuadrado ajustado	Error estándar de la estimación
1	,820 ^a	,673	,670	286171,237


a. Predictores: (Constante), n_habs, superficie

Coeficientes ^a						
Modelo		Coeficientes no estandarizados		Coeficientes estandarizados	t	Sig.
		B	Desv. Error	Beta		
1	(Constante)	-93318,831	51147,410		-1,825	,069
	superficie	8551,165	415,550	,913	20,578	<,001
	n_habs	-86700,384	20736,251	-,185	-4,181	<,001


a. Variable dependiente: precio_euros

¿Tiene sentido este modelo?

Ejercicio de interpretación




Lo real
Si mi dataset fuera sólo de tres observaciones



Interpretación de la superficie
Si todo lo demás valiera igual (entiéndase, el nº de habitaciones), por cada unidad de superficie que aumenta el precio sube en 8.551 unidades.

Ejercicio de interpretación



Lo real
Si mi dataset fuera sólo de tres observaciones

Interpretación del n° de habitaciones

.

Acaban de conocer el concepto de

CETERIS PARIBUS

Todo lo demás igual

Autocorrelación espacial

Primera ley de la geografía (Tobler, 1970):

"Todo está relacionado con todo, pero las cosas cercanas están más relacionadas que las distantes"

En el contexto inmobiliario:

- Una vivienda no existe de forma aislada, sino en un contexto espacial
- El precio de una vivienda tiende a ser similar al de sus vecinas
- Características del entorno (equipamientos, amenidades, externalidades) afectan a múltiples propiedades simultáneamente

La I de Moran cuantifica ese patrón: devuelve un valor entre -1 y $+1$ que indica si los precios similares se agrupan en el espacio, se dispersan, o se distribuyen aleatoriamente.

Autocorrelación espacial

La I de Moran, que puede ser global o local.

I de Moran global:

- Mide la autocorrelación espacial para todo el dataset en conjunto
- Nos da un solo valor que resume el patrón espacial general
- Responde a la pregunta: *"¿En general, hay autocorrelación espacial en mis datos?"*
- Es una medida promedio de toda el área de estudio
- Apunta a una sola variable

I de Moran local (LISA - Local Indicators of Spatial Association):

- Mide la autocorrelación espacial para cada observación individual
- En nuestro caso, nos da un valor por cada oferta del dataset
- Responde a la pregunta: *"¿Dónde específicamente se concentran los valores altos/bajos?"*
- Permite identificar clústeres locales y valores atípicos espaciales

Autocorrelación espacial

Ingredientes necesarios:

1. Nuestros datos: podemos elegir cualquier variable. Empecemos por el precio en euros de cada oferta.
2. Matriz de pesos espaciales (W): define quiénes son “vecinos”.

La matriz de pesos espaciales (W)

Se trata de una matriz que define qué viviendas son vecinas entre sí.

Criterios más usados:

- Contigüidad: vecinos = unidades que comparten límite (para polígonos, no es nuestro caso ahora)
- Distancia fija: vecinos = unidades dentro de X metros (ej: 500m)
- K -vecinos más cercanos: vecinos = las 5, 8 o 10 viviendas más próximas

Para datos como los nuestros, en los que cada unidad de análisis es un punto, es más común usar K -vecinos más cercanos (ej: $k=10$) o distancia fija (ej: 1000m.)

Autocorrelación espacial

Ahora vamos a calcular la I de Moran global y local de las siguientes variables:

- El precio en euros de las ofertas (*precio_euros*)
- La superficie de las ofertas (*superficie*)

Y grafiquen el resultado de la I de Moran local de cada uno. Sólo para familiarizarnos.

PSDTA: Fíjense que los valores de la I de Moran cambian según la cantidad de k -vecinos con la que construyas tu matriz W .

Prompt sugerido:

Siguiendo con el mismo gdf:

1. Calcula la I de Moran global de *precio_euros* y de *superficie*. Para ambas usa una matriz de pesos espaciales de tipo k -vecinos cercanos, siendo k =[lo eligen ustedes], con libpysal, construida a partir de la geometría del gdf. Estandariza la matriz por filas (*row_standardization*). Muestra para cada variable: el valor de la I de Moran, el p-valor y el z-score en una tabla de tres columnas.

2. Calcula la I de Moran local (LISA) de *precio_euros* y de *superficie* usando *esda.Moran_Local*. Para cada variable genera un mapa coroplético con los cuatro cuadrantes LISA (HH, LL, LH, HL) más una categoría para los no significativos ($p > 0.05$). Usa esta paleta: HH en rojo, LL en azul, LH en celeste, HL en naranja, no significativo en gris claro. El gdf tiene unas 10.000 observaciones, así que usa *markersize=1*, transparencia *alpha=0.4* y sin bordes en los puntos (*linewidth=0*). Añade un título descriptivo a cada mapa y una leyenda. Los dos mapas deben aparecer en una sola figura con dos paneles en fila.

Autocorrelación espacial

A continuación, van a graficar la distribución espacial de los residuos del modelo que más les haya convencido (*residuos_primer_ols* o *residuos_segundo_ols*).

- Y finalmente van a calcular la I de Moran global y local de esos residuos.

Si hay autocorrelación espacial en ellos, ¿qué quiere decir?

Prompt sugerido:

Siguiendo con el mismo gdf y la columna [indiquen aquí el nombre de los residuos del primer o segundo modelo, según su preferencia] (a los que me referiré en este mensaje sólo como “residuos”):

1. Genera un mapa coroplético de esos residuos. Usa la paleta divergente "RdBu_r" centrada en cero, con $\alpha=0.4$, `markersize=1` y sin bordes (`linewidth=0`). Añade una barra de color con la etiqueta "Residuos" y un título descriptivo.
2. Calcula la I de Moran global de los residuos usando la misma matriz de pesos de antes. Muestra el valor de I, el p-valor y el z-score.
3. Calcula la I de Moran local de los residuos y genera un mapa coroplético con los cuatro cuadrantes LISA más no significativos, con la misma paleta, parámetros visuales y formato de leyenda que usaste anteriormente.

Autocorrelación espacial: ¿Qué paso con los residuos de un OLS?

Recordemos un supuesto clave de los modelos OLS: Los errores (residuos) deben ser independientes entre observaciones, de ahí que se “pida” que sigan una distribución normal.

En otras palabras, lo que le pasa al residuo de una vivienda no tendría nada que ver con lo que le pasa al residuo de su vecina.

Si hay autocorrelación espacial en los residuos, ese supuesto se rompe: En algunos barrios lo predice consistentemente por encima del precio real, y en otros consistentemente por debajo.

¿Qué consecuencias tiene esto?

1. Las estimaciones de los coeficientes pueden seguir siendo insesgadas, pero los errores estándar estarán mal calculados (lo que significa que los p-valores no son fiables).
2. El modelo tiene un punto ciego geográfico, y si lo usas para valorar una vivienda en una zona donde sistemáticamente se equivoca, la valoración será mala.

Autocorrelación espacial: ¿Qué paso con los residuos de un OLS?

Sin embargo, también es importante entender por qué pasa esto:

Casi siempre porque hay algún factor con estructura espacial que no está en el modelo.

Puede ser algo tan concreto como la proximidad a una escuela muy popular, el ruido de una rotonda o la reputación informal de una calle.

La dificultad de tener residuos es que no sabemos qué factor produce la diferencia entre el valor real y el estimado.

Existen muchas maneras de abordar los problemas de autocorrelación espacial. La econometría clásica recomienda el uso de modelos de regresión espacial (Spatial Lag Models, Spatial Error Models, Spatial Durbin Models, Spatial Durbin Error Models, entre otros), pero lo cierto es que podemos aprovechar esta falencia de los modelos OLS para conocer un modelo SOTA: los XGBoost.

Carlos Marmolejo-Duarte

carlos.marmolejo@upc.edu

José Rojas-Quiroz

jose.carlos.rojas@upc.edu

