

Seminario de investigación en Gestión y Valoración Urbana y Arquitectónica

MBArch 2025/2026

Carlos Marmolejo-Duarte	carlos.marmolejo@upc.edu
José Rojas-Quiroz	jose.carlos.rojas@upc.edu

Universidad Politécnica de Cataluña
Centro de Política de Suelo y Valoraciones

Índice

1. Introducción a los modelos de Machine Learning
2. Árboles de decisión
3. Los XGBoost
4. eXplainable Artificial Intelligence (XAI): El rol de los SHAP values
5. OLS vs XGBoost: ¿Todo lo que brilla es oro?

¿Por qué usar Machine Learning en valoración inmobiliaria?

- Los modelos OLS permiten interpretar relaciones económicas con claridad.
- Sin embargo, el mercado inmobiliario presenta:
 - Relaciones no lineales
 - Interacciones complejas entre variables
 - Heterogeneidad espacial

Los modelos ML buscan mejorar la capacidad predictiva capturando esas complejidades.

Aquellos basados en *árboles de decisión* han demostrado tener un mejor rendimiento predictivo que los OLS en este contexto.


Árboles de decisión: Introducción

Un árbol de decisión divide los datos en subconjuntos cada vez más homogéneos mediante preguntas binarias.

La idea central es:


- Se formulan reglas del tipo “si ocurre esto, entonces...”
- Cada división reduce la variabilidad interna de los grupos
- La predicción final es el valor promedio dentro del grupo

Árboles de decisión: Funcionamiento




Estos modelos buscan, en primer lugar, generar particiones que generen la menor cantidad posible de *error*

Árboles de decisión: Funcionamiento




Estos modelos buscan, en primer lugar, generar particiones que generen la menor cantidad posible de *error*

Árboles de decisión: Funcionamiento



Estos modelos buscan, en primer lugar, generar particiones que generen la menor cantidad posible de *error*



Árboles de decisión: Funcionamiento




Estos modelos buscan, en primer lugar, generar particiones que generen la menor cantidad posible de *error*.

Si se “convence” en la primera partición, busca mejorar lo que hacia la derecha.

Árboles de decisión: Funcionamiento




Árboles de decisión: Funcionamiento





Convencido de que ahora debe trabajar con lo que hay a la derecha, ahora inicia una nueva evaluación para saber qué partición reducir el error asumiendo un mínimo de casos a evaluar.

Árboles de decisión: Funcionamiento




Convencido de que ahora debe trabajar con lo que hay a la derecha, ahora inicia una nueva evaluación para saber qué partición reducir el error asumiendo un mínimo de casos a evaluar.

Árboles de decisión: Funcionamiento




Árboles de decisión: Funcionamiento





Cuando se ha vuelto a convencer de la partición, se vuelve a concentrar en la zona de la derecha para buscar una nueva.

Árboles de decisión: Funcionamiento





Cuando se ha vuelto a convencer de la partición, se vuelve a concentrar en la zona de la derecha para buscar una nueva.

Árboles de decisión: Funcionamiento




Árboles de decisión: Funcionamiento




Árboles de decisión: Funcionamiento

Si ahora le pido valorar un piso de 90 m², me dirá que su precio es de _____ €.



Árboles de decisión: Funcionamiento



A diferencia de un OLS, con una línea que se ajusta a los datos, un árbol de decisión genera una función escalonada (*step function*) que puede ser sensible a los datos específicos.

Árboles de decisión: Limitaciones



Problema:

- Un árbol depende mucho de los datos concretos disponibles.
- Pequeños cambios pueden producir estructuras distintas.

Consecuencia:

- Alta variabilidad.
- Riesgo de sobreajuste.


Árboles de decisión: Limitaciones




Cuando veamos el concepto de los datos de entrenamiento y prueba entenderemos mejor esta limitación.

Los XGBoost: ¿Un solo árbol es suficiente?


Para resolver el problema mencionado, se pueden generar muchos árboles y combinar sus predicciones. Cada árbol se construye para corregir los errores del anterior, lo que mejora la capacidad predictiva.



Error cuadrático medio: 300



Error cuadrático medio: 290



Error cuadrático medio: 280

Los XGBoost: Introducción

XGBoost utiliza una estrategia de *boosting*:

- Se construye un primer árbol
- Se calculan los errores
- Se construye otro árbol para explicar esos errores
- El proceso se repite muchas veces

Cada árbol aprende lo que los anteriores no lograron explicar.

Los modelos XGBoost: Parámetros estructurales

Ejemplo de implementación

```
XGBRegressor(  
    n_estimators=500,  
    max_depth=4,  
    learning_rate=0.05,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    random_state=16  
)
```

Interpretación conceptual

- **n_estimators=500**: número total de árboles que se construyen en secuencia. Cada árbol intenta corregir los errores del anterior. Con 500 árboles y una tasa de aprendizaje pequeña, el modelo converge de forma gradual y estable. *Más árboles no siempre es mejor: a partir de cierto punto el modelo deja de mejorar. Por eso conviene combinarlo con early stopping.*

Los modelos XGBoost: Parámetros estructurales

Ejemplo de implementación

```
XGBRegressor(  
    n_estimators=500,  
    max_depth=4,  
    learning_rate=0.05,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    random_state=16  
)
```

Interpretación conceptual

- **max_depth=4**: número máximo de decisiones consecutivas dentro de cada árbol. Es decir, cuántos *niveles* de particiones se permiten antes de llegar a una predicción final. Controla directamente la complejidad de cada árbol individual.

depth=1 hace un único corte (muy simple); depth=4 puede capturar interacciones entre variables; sin embargo, depth=10 empieza a memorizar el dataset en lugar de aprender de él.

Los modelos XGBoost: Parámetros de regularización

Ejemplo de implementación

```
XGBRegressor(  
    n_estimators=500,  
    max_depth=4,  
    learning_rate=0.05,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    random_state=16  
)
```

Interpretación conceptual

- **learning_rate=0.05**: fracción del error que cada árbol nuevo se permite corregir. Un valor pequeño obliga al modelo a avanzar a pasos cortos.
Es como ajustar un instrumento de precisión: giros pequeños evitan pasarse.
Valores típicos: entre 0.01 y 0.1. Cuanto menor, más árboles necesarios.

Los modelos XGBoost: Parámetros de regularización

Ejemplo de implementación

```
XGBRegressor(  
    n_estimators=500,  
    max_depth=4,  
    learning_rate=0.05,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    random_state=16  
)
```

Interpretación conceptual

- **subsample=0.8** y **colsample_bytree=0.8**: introducen aleatoriedad al construir cada árbol, pero en ejes distintos. **subsample** usa el 80 % de las *observaciones* (filas); **colsample_bytree** usa el 80 % de las *variables* (columnas).

Ambos cumplen la misma función: forzar diversidad entre árboles para que no todos aprendan lo mismo ni memoricen los mismos casos.

Los modelos XGBoost y los datos de...¿Entrenamiento?

En modelos ML se suele dividir la información en:

- conjunto de entrenamiento (train),
- conjunto de prueba (test).

Objetivo:

- Evaluar la capacidad predictiva en datos no utilizados durante el ajuste.
- Detectar sobreajuste.

División de datos en modelos OLS

Hacer esta división depende del objetivo del análisis.

Si el objetivo es:

- inferencia económica $\rightarrow$ no es necesario
- predicción $\rightarrow$ sí puede hacerse, aunque no es común

Mi recomendación es no hacerlo salvo que se quiera comparar la capacidad predictiva de un OLS con un modelo ML.

Los modelos XGBoost: ¿Y los coeficientes β ?

En OLS:

- existe una ecuación explícita
- cada variable tiene un efecto marginal constante (es decir, un coeficiente β)

En XGBoost:

- existen muchas reglas no lineales combinadas
- el resultado depende de procesos aleatorios
- no hay un coeficiente único por variable

Esto dificulta la interpretación económica directa.

Los modelos XGBoost: ¿Y los coeficientes β ?

En OLS:

- existe una ecuación explícita
- cada variable tiene un efecto marginal constante (es decir, un coeficiente β)

En XGBoost:

- existen muchas reglas no lineales combinadas
- el resultado depende de procesos aleatorios
- no hay un coeficiente único por variable

En valoración inmobiliaria, la predicción no es suficiente. Necesitamos justificar el resultado:

- ¿Qué variables han empujado el precio hacia arriba?
- ¿Cuáles lo han penalizado?
- ¿En qué medida ha influido cada una?

Usualmente este ha sido el motivo por el que modelos de este tipo, como los XGBoost, no se han utilizado en análisis urbano con gran frecuencia (además de su novicidad).

Se les considera *black boxes*.

Sin embargo, han aparecido herramientas para acercarnos a su interpretabilidad.


SHAP values: Intuición

Imaginen que el precio medio de un piso en Barcelona es 4.500 €/m². El tuyo vale 5.200 €/m². La diferencia son 700 €/m². La pregunta es: ¿cómo repartimos esos 700 entre las características (superficie, ubicación, estado, planta, etc.)?

La idea de SHAP es empezar desde un valor base (el precio medio) e ir añadiendo información del piso progresivamente. Cada vez que se añade una característica, se mide cuánto cambia la predicción. Ese cambio es la contribución de esa característica.

La suma de todas las contribuciones coincide exactamente con la diferencia entre el precio medio y la predicción del modelo.

SHAP values: Interpretación



Eje X: magnitud y dirección

Valores positivos: la variable empuja la predicción hacia arriba. Valores negativos: la penaliza.

Eje Y: importancia global

Las variables están ordenadas de mayor a menor importancia media. Las que más explican el modelo aparecen arriba.

Color: valor de la variable

Rojo: valor alto de esa variable en la observación concreta. Azul: valor bajo. Permite ver si una variable sube o baja el precio según su magnitud.

Los SHAP values: Utilidad en análisis urbano

Los SHAP values permiten traducir el modelo a preguntas concretas de valoración:

¿Por qué el modelo valora tan alto *un* piso en Gràcia?

superficie: +120 €/m²


planta: +50 €/m²

antigüedad: -25 €/m²

distancia_plaza_cat: -10 €/m²

El modelo se vuelve auditable: cada componente del precio tiene una explicación.

Árboles de decisión: Utilidad en análisis urbano



Cuando se mapean los SHAP values en el espacio, emergen patrones territoriales.

Ejercicio: modelo XGBoost

Usando las mismas variables independientes que en el OLS de la sesión anterior, obtengan un modelo XGBoost con `XGBRegressor` de la librería `xgboost`.

Algunas notas metodológicas:

- No es necesario usar `log_precio_euros` como variable dependiente. XGBoost no asume linealidad ni normalidad de residuos
- No es necesario que especifiquen la no linealidad de `superficie_2`

Obtengan:

- R^2 y RMSE del modelo
- Histograma de residuos con curva de densidad (KDE)
- Los residuos guardados en una columna llamada `residuos_primer_xgboost`
- Un beeswarm plot de SHAP values

Ejercicio: modelo XGBoost



Prompt sugerido:

Tengo un GeoDataFrame llamado `gdf`. Quiero estimar un modelo XGBoost con `XGBRegressor` de la librería `xgboost`. La variable dependiente es `precio_euros`. Las variables independientes son [completen ustedes aquí]. Haz lo siguiente:



- 1. Divide los datos en train (80 %) y test (20 %) con `random_state=16`. Ajusta el modelo sobre train y evalúalo sobre test. Muestra el R^2 y el RMSE.*
- 2. Aplica el modelo a todo el dataset y vuelve a calcular el R^2 y el RMSE. A continuación, guardar los residuos de todo el dataset en una nueva columna llamada `residuos_primer_xgboost`. Genera también un histograma de esos residuos con el eje Y en densidad y una curva KDE superpuesta.*
- 3. Calcula los SHAP values con `shap.Explainer` y genera un beeswarm plot sobre el conjunto de test. Usa `show=False` y guarda la figura con `bbox_inches="tight"`.*

¿Qué ventajas supone un XGBoost sobre un OLS?
¿Hay algo en lo que un OLS sea mejor?

Comparación de residuos entre modelos



Comparación de residuos entre modelos



Qué ventajas y limitaciones presenta XGBoost

Ventajas:

- alta precisión predictiva,
- captura no linealidades,
- menor autocorrelación espacial de residuos.

Limitaciones:

- falta de coeficientes claros,
- menor transparencia,
- dificultad de comunicación profesional.

Carlos Marmolejo-Duarte carlos.marmolejo@upc.edu
José Rojas-Quiroz jose.carlos.rojas@upc.edu

Universidad Politécnica de Cataluña
Centro de Política de Suelo y Valoraciones