

Seminario de investigación en Gestión y Valoración Urbana y Arquitectónica

MBArch 2025/2026

Carlos Marmolejo-Duarte	carlos.marmolejo@upc.edu
José Rojas-Quiroz	jose.carlos.rojas@upc.edu

Universidad Politécnica de Cataluña
Centro de Política de Suelo y Valoraciones

Índice

1. Los residuos de los modelos y su utilidad práctica
2. Análisis de Componentes Principales (PCA)
3. Método k -means

¿Qué nos indican los residuos?

Los residuos representan todo aquello que nuestro modelo no puede capturar:

$$\varepsilon = Y - \hat{Y}$$

donde Y es el precio real y $\hat{Y}$ es el precio predicho por el modelo.

Una forma de interpretarlos es como la “fuerza” de aquellas variables que no están en nuestro dataset.

Siempre van a haber condiciones (entiéndase, *variables*) que se nos escapen, por más que intentemos capturarlas.

Caso: Las vistas al mar

El Dr. Marmolejo-Duarte, mi **querídisimo** director de tesis, en algún momento les debe haber contado este caso:

- Elaboró un modelo que no predijo bien el precio de viviendas cercanas a la playa
- Incluso teniendo una variable dummy `primera_linea` (0/1, este último cuando estaba a 300 metros de la línea de mar)
- ¿El problema? Lo que influenciaba el precio no era la cercanía: eran las vistas al mar

¿Se puede meter eso en un modelo?

Quizá hoy hay más herramientas para hacerlo. En ese momento no.

El error de su modelo se explicaba, en parte, por esa condición, pero no había cómo saberlo.

Residuos negativos como oportunidades de inversión

Si un residuo es negativo:

- El precio real está por debajo de lo que el modelo predice
- ¿Se trata de chollos/gangas/oportunidades de inversión?
- Si nuestro modelo tiene un RMSE muy bajo, con seguridad sí

Ejemplo:

- Modelo predice: 5.000 €/m²
- Precio real: 4.200 €/m²
- Residuo: -800 €/m²

Lo puedes comprar y hay muchas posibilidades de poder revenderlo a un precio más alto.

Residuos positivos: ¿Expectativas de rentabilidad?


Si un residuo es positivo:

- El precio real está por encima de lo que el modelo predice
- ¿Expectativas de ganancia mayor que la que nuestras variables pueden captar?
- Puede ser que se esté rehabilitando un parque frente a un piso
- Y como no lo podemos captar todo (porque, oh sorpresa, la vida es así: compleja), nuestro modelo lo valora en menor medida
- Pero la prima de valor existe

Si se produce de manera sistemática en una zona:


- Puede tratarse de una expectativa de rentabilidad
- Atributos de la realidad que “pujan” el precio hacia arriba

Residuos positivos: ¿Expectativas de rentabilidad?




Una de las cosas que queremos identificar es en qué zonas hay más posibilidad de que inversores se interesen por comprar más edificabilidad. Y los residuos positivos nos pueden ayudar.

Residuos positivos: ¿Expectativas de rentabilidad?



Si nos quedamos sólo con los residuos positivos encontramos esto.
Todavía nada muy claro.

Residuos positivos: ¿Expectativas de rentabilidad?



Pero si contamos el total de residuos por *zonas* y calculamos qué porcentaje son positivos, podemos acercarnos a ver en qué zonas hay mayor expectativas de rentabilidad.

El Análisis de Componentes Principales: una herramienta para reducir dimensiones

PCA: ¿Por qué es útil?

El Análisis de Componentes Principales es útil en nuestro caso por dos motivos:

- Al elaborar un MCO requerimos que no exista multicolinealidad
- Al calcular los SHAP values necesitamos que las variables no estén correlacionadas entre sí, de lo contrario sobrevaloran su impacto en la estimación de la variable dependiente
 - El modelo puede predecir bien, pero la interpretación se complica

PCA: ¿Qué hace?

Imagina que tenemos tres variables que miden cosas distintas pero relacionadas:


- Distancia a Plaça Catalunya
- Distancia a Plaça Francesc Macià
- Distancia a la Av. Diagonal

Si un piso está lejos de una, probablemente esté lejos de las demás. Las tres miden esencialmente lo mismo: centralidad urbana.

El PCA detecta eso y las combina en un solo componente, como un *índice de centralidad*.

¿El resultado? En lugar de 3 variables correlacionadas obtenemos 1 componente que resume toda la información.

El problema: variables correlacionadas



Las tres variables de distancia están altamente correlacionadas: si un piso está lejos de Plaça Catalunya, también lo estará de las otras referencias.

Meterlas todas en un MCO provocaría multicolinealidad.

El PCA las fusiona en un solo componente que recoge lo que tienen en común: la centralidad.

PCA: Varianza explicada por *componente*

Cuando hagamos un PCA, obtendremos *componentes*, y lo primero que veremos es una tabla como esta: la varianza de las tres variables que explica cada uno de ellos. En otras palabras, ¿cuánta información del total captura cada componente?

Componente	Varianza (%)	Acumulada (%)
PC1	74.20 %	74.20 %
PC2	15.97 %	90.17 %
PC3	9.83 %	100.00 %

Noten que con el primer componente ya superamos el 70 %:

- Un solo componente captura la mayor parte de la información
- Miramos la columna “Acumulada” y decidimos cuántos *componentes* necesitaremos. Usualmente el umbral es del 70 %.

PCA: ¿Cuántos *componentes* necesitamos?

Si la intención es reducir dimensiones, 1–2 componentes suelen ser suficientes.
Más componentes = más variables en el MCO: ¿para qué hacer PCA entonces?
Pero, como siempre, depende del objetivo de su investigación.

PCA: Cargas de *componentes* (loadings)

Una vez obtenidos los *componentes*, ¿cómo los interpretamos?

En nuestro ejemplo, sabemos que el primero explica más del 70 % de nuestras tres variables.

Pero... ¿Cómo se *lee*?

Las cargas indican cuánto contribuye cada variable a cada componente.

Variable	PC1	PC2	PC3
Dist. Plaça Catalunya	0.356	0.282	0.891
Dist. Plaça F. Macià	0.900	0.263	0.347
Dist. Av. Diagonal	0.243	0.936	0.255

- PC1 *es* principalmente la distancia a Plaça Francesc Macià (0.900): eje residencial/comercial
- PC2 *es* principalmente la distancia a la Diagonal (0.936): eje municipal
- PC3 *es* principalmente la distancia a Plaça Catalunya (0.891): eje de centralidad

PCA: ¿Y si los componentes están correlacionados?

Una duda que me surgió cuando conocí de esta técnica:

- Si hay más de un componente
- Y son componentes que vienen de variables altamente correlacionadas
- ¿No les pasa lo mismo a ellos? ¿No se correlacionan?

Respuesta:

- Por construcción, los componentes PCA son ortogonales (correlación = 0)
- Si usas una rotación oblicua (no Varimax), pueden estar correlacionados, pero no será nuestro caso

PCA: Un concepto adicional, la rotación Varimax

Cuando el PCA genera componentes, puede ser difícil interpretar qué “mide” cada uno: todas las variables tienden a tener pesos similares en todos ellos.

La rotación Varimax *aclara la imagen*: rota los componentes para que cada variable cargue con fuerza en uno solo de ellos.

En el ejemplo del índice de centralidad:

- Sin rotación: las tres distancias tendrían pesos parecidos en todos los componentes
- Con Varimax:
 - PC1 carga principalmente sobre distancia a Plaça Francesc Macià (0.900)
 - PC2 carga sobre la Diagonal (0.936): eje municipal

Como recomendación, al elaborar un PCA asegúrense de pedir los componentes con rotación Varimax.

También podríamos aplicar PCA a las dos variables que obtendremos por *zona*, de manera que obtengamos un único indicador de *potencial de zona receptora*.

Ahora veamos una técnica con fines distintos: los
 k -means

k -means: ¿Qué es esta técnica?


Es un algoritmo de clustering (agrupamiento). Su objetivo es:

- Agrupar observaciones en k clusters (grupos)
- Minimizar la distancia intra-cluster
- Maximizar la distancia inter-cluster

Características:

- No supervisado (no necesita etiquetas previas)
- Iterativo: mejora la solución en cada paso
- Sensible a la inicialización

k -means: Método de cálculo



1. Seleccionar k centroides iniciales aleatoriamente
2. Asignar cada observación al centroide más cercano
3. Recalcular los centroides como el promedio de las observaciones asignadas
4. Repetir pasos 2-3 hasta que (1) los centroides no cambien o (2) se alcance un número máximo de iteraciones.

k -means: Método de cálculo

Este vídeo de Avi Chawla lo explica de manera más fluida.

¿Para qué puede servir k -means?

En valoración inmobiliaria:

Identificar submercados de vivienda

¿Por qué es útil?

- El mercado inmobiliario no es homogéneo
- Diferentes segmentos operan con lógicas distintas
- Vivienda de lujo vs vivienda social
- Centro vs periferia

Ventaja:

- Permite modelar cada submercado por separado
- Reduce heterogeneidad y outliers
- Mejora la normalidad de los residuos

Antes de pedirles que hagan cálculos, quiero que vean un ejercicio de clustering que hice para identificar submercados inmobiliarios con nuestros datos.

Usé tres variables: `precio_unitario` (€/m²), `rm_h` (índice de renta media del barrio) y `calidad_construccion` (escala del 1-9)

Identificación de submercados

Variables para clustering:

- `precio_unitario` (€/m²)
- `rm_h` (índice de renta media del barrio)
- `calidad_construccion` (escala de calidad)

Proceso:

1. Normalizar las variables (z -scores)
2. Aplicar k -means con $k = 3, 4, 5 \dots$ clusters
3. Evaluar la calidad con el método del codo (elbow method)
4. Seleccionar el número óptimo de clusters

Normalización: Necesidad conceptual

El k -means agrupa por distancia: busca qué observaciones están “cerca” entre sí.

El problema: si las variables tienen escalas muy distintas, la distancia queda dominada por la variable con los valores más grandes, independientemente de su importancia real.

Es decir, con nuestros datos:

- `precio_unitario`: oscila entre 1.000 y 15.000 €/m² → diferencias de miles
- `edu_sup_pct`: oscila entre 10 y 60 % → diferencias de decenas

Sin normalizar, el precio *aplasta* al resto: el clustering sería casi exclusivamente por precio.

Normalización: ¿Cómo se calculan los z -scores?

Para cada observación x_i de una variable, su z -score es:

$$z_i = \frac{x_i - \mu}{\sigma}$$

donde μ es la media y σ la desviación estándar de esa variable.

El resultado: todas las variables quedan con media 0 y desviación estándar 1.

Hay otras formas de normalizar (por ejemplo, escalar al rango $[0, 1]$), pero los z -scores son menos sensibles a valores extremos, algo habitual en datos inmobiliarios.


Método del codo (Elbow method)

- Mide la inercia: suma de las distancias al cuadrado entre cada punto y el centroide de su cluster
- En palabras sencillas mide qué tanto son de parecidos los datos dentro de cada grupo
- A mayor k , menor inercia (los grupos son más pequeños y homogéneos)
- Pero más clusters no siempre es mejor, porque perdemos simplicidad

¿Qué buscamos?


- El punto donde añadir un cluster más no mejora mucho la inercia
- Ese punto es el “codo” de la curva
- Balance entre simplicidad (pocos clusters) y ajuste (baja inercia)

Método del codo (Elbow method)



El “codo” indica el número óptimo de clusters: balance entre simplicidad y ajuste.

Visualización de submercados




Tres submercados identificados: lujo, medio, económico.

La técnica te ofrece la cantidad de grupos que tú le pidas. El problema, conceptualmente, es cómo definirlos. ¿Cómo sé en este caso cuál es el submercado de lujo, el económico o el medio?

He ahí el *quid* de la cuestión. Lo vamos a ver con un ejercicio.

Pero antes... ¿Estos clústeres tendrán un sentido espacial?

Distribución espacial de submercados



Los submercados muestran patrones espaciales claros en el territorio.

k -means y modelización por submercados

Estrategia:

Se pueden hacer MCO por cada submercado

Ventajas:

- Se reduce la posibilidad de encontrar outliers
- Los coeficientes son más estables dentro de cada grupo
- Mejora la distribución normal de los errores
- Cada submercado puede tener su propia “lógica” de precios

Ejemplo:

- En submercado de lujo: las vistas pueden importar más
- En submercado económico: la proximidad al transporte público

Tarea para casa:

Con submercados identificados, estimen modelos OLS por cada submercado y vean sus resultados.

¿Tendrán sentido? ¿Cumplen con los supuestos?

Carlos Marmolejo-Duarte carlos.marmolejo@upc.edu
José Rojas-Quiroz jose.carlos.rojas@upc.edu

Universidad Politécnica de Cataluña
Centro de Política de Suelo y Valoraciones